

UnifAI Observability Master Deep-Dive Guide

UnifAI கண்காணிப்பு அமைப்பின் மாழமையான உடற்குறை ஆய்வு (Tech & Non-Tech Master Manual)

1. Observability Architecture & Ecosystem Overview

AI Observability provides complete visibility into AI consumption, financial burn rates, latency percentiles, and security compliance. UnifAI decouples telemetry logging from the critical proxy path using lock-free atomic buffers and streaming connectors to ensure sub-millisecond response overhead.

2. Detailed Feature Dissection (6 Core Observability Features)

Dashboard (கண்காணிப்பு மாகப்புத் திரை) (/workspace/dashboard)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உரவகம் (Analogy): விமானத்தின் காக்பிட் (Airplane Cockpit) அல்லது சமூகக் காரின் டிஷ்போர்டு போன்றது.
- விளக்கம் (Explanation): ஒரு கார் ஓட்டும்போது ஸ்பீடோமீட்டர் வேகம், பெட்ரோல் அளவு மற்றும் இன்ஜின் நிலைமை காட்டுவது போல, கம்பனியில் AI பயன்பாடு எப்படி நடக்கிறது என்பதை தலைவர்கள் ஒரே பார்வையில் பார்க்கும் இடம். இன்று எத்தனை லட்சம் AI கேள்விகள் கேட்கப்பட்டது, எவ்வளவு டாலர் செலவாகியுள்ளது, எந்த AI மாடல் வகைமாக இயங்குகிறது, எந்த டீம் அதிக டோக்கன் பயன்படுத்துகிறது என்பதை நிகழ்நேரத்தில் (Realtime Graphs) காட்டும்.
- வணிக மதிப்பு (Business Value): செலவை உடனடிக் காட்டுவது கட்டுப்படுத்தலாம்; திடீரென பில் எகிறாமல் தடுக்கலாம்; AI அமைப்பின் வகைத்தலை கண்காணிக்கலாம்.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: The Dashboard is powered by a persistent WebSocket connection ('useWebSocket') synchronized with TanStack Query. Backend telemetry is collected at the FastHTTP transport layer using lock-free atomic counters (sync/atomic). Metrics are aggregated into time-series buckets (1-min, 5-min, 1-hour intervals) and queried via PostgreSQL. Calculates percentile response times (p50, p90, p95, p99) and Time-To-First-Token (TTFT). Dynamically prices token volumes using live rules from Pricing Overrides.
- Endpoints: GET /api/v1/dashboard/stats, GET /api/v1/dashboard/histogram, WS /api/v1/ws/dashboard

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

- மேல்புற கட்டுப்பாடுகள் (Top Bar Controls):
 - Time Period Selector: Quick toggles for 1h, 24h, 7d, 30d, and custom date range.
 - Date Range Picker (DateTimePickerWithRange): Calendar and time modal for custom historical analysis.
 - Timezone Dropdown: Switch between UTC and Local Browser Timezone.
 - Export Popover Button: Download metrics in CSV, JSON, or PNG chart formats.
 - Filter Sidebar Toggle Button: Slides out 'LogsFilterSidebar' to filter by Virtual Keys, Providers, and Models.
- மத்திய திரைக் கூறுகள் (Tabs & Views):
 - Overview Tab: Request volume charts, total token consumption, total spend (\$), and p50/p95/p99 latency curves.
 - Provider Usage Tab: Comparative traffic distribution across OpenAI, Anthropic, Bedrock, and Ollama.
 - Model Rankings Tab: Leaderboard of top models ranked by request count, cost, and latency.
 - Dimension Rankings Tab: Usage breakdown by custom tags passed in 'x-uf-dim-' (e.g. environment, department).
 - MCP Tab: Volume and dollar cost incurred specifically by Model Context Protocol tool executions.
 - Chart Type Toggle: Button switching between Line Graph and Bar Chart views.
- கீழ்புற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - Model Filter Select: Dropdown isolating individual model trends.
 - Cache Hit Ratio Meter: Live gauge showing percentage of requests resolved via Semantic Cache at \$0 cost.

Connections & Structure Map (இணைப்புகள்):

- தரவணகம் பற்றாமை: Aggregates real-time data from LLM Logs, Pricing Overrides, and Semantic Caching.
- இயக்கம் கூறுகள்: If error rates spike >5% or spending exceeds 80% of budget, triggers automated alerts to Alert Channels (Slack/PagerDuty).

Production Use Case: ஒரு ஃபின்டெக் கம்பனியின் CTO காலநிலை 9 மணிக்கு டிஷ்போர்டைப் பார்த்து, நேற்று இரவு OpenAI-ல் ஏற்பட்ட லேடென்சி ஸ்பைக்கை (p99 > 4000ms) கண்டறிந்து, ரூட்டிங் விதியை Claude-க்கு மாற்ற உத்தரவிடுகிறார்.

LLM Logs (AI களோரிக்கை பரிவர்த்தனை பதிவக்டு) (/workspace/logs)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உராவகம் (Analogy): வங்கியின் பாஸ்புக் (Bank Statement) + அலுவலகத்தின் சிசிடிவி கமேரா பதிவு (CCTV Footage).
- விளக்கம் (Explanation): யார், எப்போது, எந்த AI மாடலிடம் என்ன களேவி கட்டார்கள்? மாடல் என்ன பதில் தந்தது? அதற்கு எத்தனை ரூபாய்டாலர் செலவானது? பதில் வர எத்தனை விநாடி எடுத்தது? ஏதனும் ரகசிய ஆதார்/கிரபிட் கார்டு தகவல்கள் மறகைக்கப்பட்டதா? என்பதை ஒவ்வொரு பரிவர்த்தனையாக அகுவறே ஆணிவறோகப் பதிவு செய்து வகைகும் ரசீது ஸுததகம்.
- வணிக மதிப்பு (Business Value): பிழகைகளை உடனடியாக சரிசெய்யலாம் (Debugging), சட்ட ரீதியான தணிக்ககைக்டு (Audit Compliance) ஸுழ ஆதாரம் கிடகைக்டு.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: Implemented with an asynchronous, non-blocking ring-buffer queue ('framework/logstore'). FastHTTP request context captures exact request headers, messages, and wire bytes. A decoupled worker pool writes micro-batches to PostgreSQL using 'pgx v5' connection pooling. Every log row records: request_id, session_id, virtual_key_id, provider, requested_model, resolved_model, prompt_tokens, completion_tokens, total_tokens, cost_usd, latency_ms, ttft_ms, status_code, and guardrail_verdict.
- Endpoints: GET /api/v1/logs, GET /api/v1/logs/:id, POST /api/v1/logs/delete

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

1. மலேபுற கட்டப்பாடுகள் (Top Bar Controls):
 - Top Metric Cards: Live animated counters for Total Requests, Total Cost (\$), Total Tokens, and Errors.
 - Search Input Bar: Full-text and regex search matching keywords inside prompt or completion text.
 - WebSocket Live Indicator: Animated green pulsing dot indicating real-time log ingestion.
 - Column Customizer (useColumnConfig): Dropdown to show/hide specific table columns.
 - Export CSV Button: Download filtered log entries as CSV.
 - Delete Logs Button: Role-protected button (RBAC) to delete historical records.
2. மத்திய திரகை கூறுகள் (Tabs & Views):
 - Collapsible Logs Volume Chart: Hourly/Daily bar graph displaying traffic spikes above the table.
 - Logs Data Table: Columns for Timestamp, Status (Badge), Model (Original -> Resolved), Provider Icon, Virtual Key, Customer ID, Latency, Tokens, Cost (\$), Actions.
3. கீழ்புற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - LogDetailSheet (Slide-over): Opens on row click. 4 Tabs: (1) Request (headers & prompt), (2) Response (completion & finish reason), (3) Guardrails (verdict & redacted entities), (4) Trace (spans & TTFT breakdown).
 - SessionDetailsSheet (Slide-over): Chronological multi-turn conversation replay for requests sharing the same 'x-uf-session-id'.
 - Row Action Dropdown: 'Copy Request ID', 'Copy cURL Command', 'View Raw Wire Bytes'.

Connections & Structure Map (இணைப்புகள்):

- தரவகை பெறுமிடம்: Intercepts every HTTP and WebSocket request flowing through the FastHTTP Gateway.
- இயக்கும் கூறுகள்: Feeds Dashboard metrics, drains event streams to Connectors (Datadog/Kafka), and validates Guardrail rule accuracy.

Production Use Case: ஒரு மரூத்துவர் AI-யிடம் ஒரு நயோயாளியின் தரவகை உள்ளிடும்போது, அவரது பயெர் மற்றும் மொபகைல் எண் '[REDACTED_PII]' என மாற்றப்பட்ட பாதுகாப்பாக அனுப்பப்பட்டதா என சகெயூரிட்டி அதிகாரி Logs-ல் சரிபார்க்கிறார்.

MCP Logs (ஏஜென்ட் டூல்ஸ் இயக்கப் பதிவடோ) (/workspace/mcp-logs)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உராவகம் (Analogy): ஒரு மெக்கானிக் அல்லது ஊழியர் பயன்படுத்திய கருவிகளின் டைரி (Tools Usage Audit Book).
- விளக்கம் (Explanation): இன்றைய AI வறும் பதில் மட்டும் சொல்வதில்லை; அது டேட்டாபேஸை அணுகுகிறது, GitHub-ல் கோட் உருவாக்குகிறது, Slack-ல் மெசேஜ் அனுப்புகிறது. அப்படி AI ஏஜென்ட் இயக்கிய ஒவ்வொரு வளிப்புற டூலின் (External Tool) செயல்பாடுகளையும், என்ன இன்புட் கொடுத்து என்ன ரிசல்ட் எடுத்தது என்பதையும் பதிவு செய்யும் இடம்.
- வணிக மதிப்பு (Business Value): AI ஏஜென்ட் தவறான டேட்டாபேஸ் கமாண்ட் இயக்கிவிட்டதா அல்லது ஹகே ஆகிவிட்டதா என்பதை கண்காணிக்கலாம்.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: Implemented in 'core/mcp/exec.go'. Instruments tool execution lifecycles across stdio subprocesses and HTTP SSE transports. Captures calling agent identity, target MCP server, tool function name, parsed input JSON arguments, execution duration in milliseconds, output JSON return schema, and any stderr/exception traces.
- Endpoints: GET /api/v1/mcp-logs, GET /api/v1/mcp-logs/:id

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

- மலேபாற கட்டுப்பாடுகள் (Top Bar Controls):
 - Tool Name Filter Dropdown: Filter by specific tool (e.g. 'execute_sql_query', 'read_file').
 - Server Label Dropdown: Filter by MCP server (e.g. 'github', 'postgres', 'slack').
 - Time Window Selector: Filter tool invocations by time.
 - Export Button: Export tool audit logs.
- மத்திய திரைக் கூறுகள் (Tabs & Views):
 - MCP Logs Table: Columns for Timestamp, Tool Name (Badge), Server Name, Status (Success/Failed), Duration (ms), Virtual Key, User Session ID.
- கீழ்பாற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - ToolExecutionDetailSheet (Slide-over): Detailed inspector with: (1) Arguments Tab (JSON inputs sent to the tool), (2) Results Tab (JSON response returned by tool), (3) Error Stack Trace Tab.

Connections & Structure Map (இணைப்புகள்):

- தரவடை பறொமிடம்: Triggered by MCP Gateway execution whenever an LLM initiates a Tool Calling loop.
- இயக்கம் கூறுகள்: Tied to Tool Groups and Auth Sessions. If a tool fails repeatedly, updates Circuit Breaker and Alert Channels.

Production Use Case: ஒரு AI கோபிங் ஏஜென்ட் GitHub Repositories-ல் தவேயைல்லாத கோப்பை நீக்கிவிட்டதா என்பதை MCP Logs-ல் சன்றோ 'delete_file' டூலின் இன்புட் ஆர்குமெண்ட்டை எடுத்து ஆராய்கிறார்கள்.

Browser AI (பிரவசர் பாதுகாப்பு & DLP ப்ராக்ஸி) (/workspace/browser-ai)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உராவகம் (Analogy): அலுவலக வாயிலில் இரூக்கம் சக்யூரிட்டி கார்டு (Security Checkpost at the Gate).
- விளக்கம் (Explanation): ஊழியர்கள் தங்கள் அலுவலக லப்டாப்பில் பொது இணையதளங்களான ChatGPT, Claude, Perplexity போன்றவற்றைப் பயன்படுத்தும்போது, நிறுவனத்தின் ரகசிய சோர்ஸ் கோட், பாஸ்வர்ட்கள், வாடிக்கையாளர் விபரங்கள் ஆகியவற்றை காப்பி-பேஸ்ட் செய்துவிடாமல் நடுவில் நின்று தடுத்து நிறுத்தும் டிஜிட்டல் சக்யூரிட்டி கார்டு.
- வணிக மதிப்பு (Business Value): நிறுவனத்தின் மிகப்பெரிய பாதுகாப்பு அச்சுறுத்தலான 'Employee Data Leakage'-ஐ 100% தடுத்து நிறுத்துகிறது.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: A hybrid two-layer architecture: (1) A lightweight Python proxy daemon ('apps/browser-guard/proxy/browser_ai_proxy.py') with Chrome/Edge extensions deployed via corporate MDM, and (2) a central management UI in UnifAI. Intercepts HTTPS paste events on designated AI domains, evaluates Presidio DLP regexes, runs local Ollama classification models, extracts text from uploaded attachments (PDF, DOCX), and enforces block/mask actions.
- Endpoints: GET /api/v1/browser-ai/logs, POST /api/v1/browser-ai/rules, POST /api/v1/browser-ai/targets

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

1. மலேபாற கட்டுப்பாடுகள் (Top Bar Controls):
 - 5 Main Tabs: Logs Tab, Rules Tab, Target Websites Tab, Agents Tab, Settings Tab.
 - Agent Heartbeat Status Bar: Shows active, online, and disconnected employee machines.
2. மத்திய திரைக் கூறுகள் (Tabs & Views):
 - Rules Tab: List of DLP policies with toggle switches (Enabled/Disabled).
 - Target Websites Tab: Directory of monitored AI websites (chatgpt.com, claude.ai) with host roles (Allow/Block).
 - Agents Tab: Table of employee laptops (Hostname, IP, OS, Agent Version, Last Heartbeat).
 - Logs Tab: Intercepted queries showing employee ID, target domain, matched rule, and blocked text preview.
3. கீழ்பாற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - + Create Rule Button: Modal with Policy-to-Regex AI generator (converts English descriptions to Regex).
 - + Add Target Website Dialog: Add new AI websites to monitor with attachment scanning toggle.
 - Save Uninstall Key Button: Sets tamper-proof password required to remove the agent from laptops.
 - Bulk Delete Agents Button: Clean up decommissioned employee machines.

Connections & Structure Map (இணைப்புகள்):

- தரவரை பறொமிடம்: Receives real-time intercepted traffic from employee laptop daemons via WebSocket/HTTP.
- இயக்கம் கூறுகள்: Shares Guardrail Providers (Presidio); writes violations directly into Audit Logs and Alert Channels.

Production Use Case: ஒரு ஜூனியர் டெவலப்பர் தனது நிறுவனத்தின் AWS Secret Key-ஐ ChatGPT-ல் பேஸ்ட் செய்ய முயலும்போது, Browser AI அதை உடனடியாக தடுத்து நிறுத்தி, 'Corporate Policy Violation' எச்சரிக்கையை திரையில் காட்டுகிறது.

Connectors (வெளிப்புற கண்காணிப்பு இணைப்பு காமூலங்கள்) (/workspace/observability)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உராவகம் (Analogy): தொழிற்சாலையிலிருந்து கழிவாநீர் அல்லது பொருட்களை பரெய காமூல மூலம் நகராட்சி டேங்கிற்கு அனுப்புவது போன்ற எக்ஸ்போர்ட் பைப்லைன் (Export Pipeline).
- விளக்கம் (Explanation): UnifAI-க்கூள் மட்டும் தகவல்களை வதைத்திருக்காமல், நிறுவனத்தின் கார்ப்பரேட் கண்காணிப்பு தளங்களான Datadog, New Relic, Google BigQuery, அல்லது Kafka-வாக்கு இந்த AI லாக் தகவல்களை நிகழ்நேரத்தில் தானாகவே பம்பு செய்து அனுப்பும் இணைப்பு காமூலங்கள்.
- வணிக மதிப்பு (Business Value): நிறுவனத்தின் அனைத்து மனெப்பொருள் மற்றும் AI சலெவாகளை ஒரே பரெய எண்டர்பிரைஸ் டேஷ்போர்டில் ஒரங்கிணைக்கலாம்.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: Implemented in 'framework/connectors/runtime.go'. Employs a decoupled ring-buffer worker pipeline. Separates telemetry export from the critical path of the gateway to maintain zero-latency proxying. Formats internal telemetry into vendor-specific schemas and streams them asynchronously with configurable batch sizes, flush intervals (ms), retry logic, and exponential jitter backoff.
- Endpoints: GET /api/v1/connectors, POST /api/v1/connectors, POST /api/v1/connectors/:id/test

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

1. மலேபாற கட்டப்பாடுகள் (Top Bar Controls):
 - + Add Connector Button: Opens creation sheet for external platforms.
 - Active Connectors Status Badges: Displays health indicators (Green = Streaming, Red = Unreachable).
2. மத்திய திரைக் கூறுகள் (Tabs & Views):
 - Connector Cards Grid: Datadog, New Relic, Apache Kafka, Google BigQuery, Google PubSub, OpenTelemetry (OTel).
3. கீழ்பாற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - ConnectorConfigSheet (Slide-over): Form inputs for API Key, Endpoint URL, Buffer Size Slider, Flush Interval (ms), Header Whitelist.
 - Test Connection Button: Dispatches a synthetic ping payload to verify credentials and connectivity before saving.

Connections & Structure Map (இணைப்புகள்):

- தரவன பறெமிடம்: Drains event records continuously from LLM Logs, MCP Logs, and Audit Logs.
- இயக்கம் கூறுகள்: Pushes live AI telemetry to external corporate data lakes and SIEM systems.

Production Use Case: ஒரு வங்கியின் பில்லிங் சாப்ட்வரே, Google BigQuery-ல் UnifAI Connectors வழியாக வரம் வாபிக்கையாளர் டோக்கன் டேட்டாவன வதைது தானாகவே மாதாந்திர இன்வாய்ஸ் தயாரிக்கிறது.

Logs Settings (பதிவடே அமைப்புகள் & கொள்கைகள்) (/workspace/config/logging)

Non-Tech Perspective (எளிய வணிக விளக்கம்):

- உரவகம் (Analogy): ஆவணங்களை பாதுகாக்கும் காப்பகம் மற்றும் ஆவண அழிப்பு கொள்கை (Document Retention & Shredding Policy).
- விளக்கம் (Explanation): பழைய லாக் விபரங்களை எத்தனை நாட்கள் வைத்திருக்க வேண்டும்? எப்போது தானாக அழிக்க வேண்டும்? மிகவும் ரகசியமான மரூத்துவ/வங்கி உரையாடல்களை லாக் செய்யாமல் மறைக்க வேண்டுமா? பழைய டேட்டாவை மலிவான கிளவுட் ஸ்டோரேஜிற்கு (AWS S3) மாற்ற வேண்டுமா? என்பதை தீர்மானிக்கும் கொள்கை அறவை.
- வணிக மதிப்பு (Business Value): சர்வர் ஸ்டோரேஜே செலவு மிச்சமாகும்; அரசாங்கத்தின் GDPR / HIPAA சட்ட விதிகளுக்கு இணங்கலாம்.

Tech Perspective (தொழில்நுட்ப கட்டமைப்பு):

- Backend Architecture: Located in 'ui/app/workspace/config/views/loggingView.tsx' and backend garbage collection scheduler. Controls internal database vacuuming routines, FastHTTP request context logging filters, and AWS S3 / Google Cloud Storage multi-part blob upload routines for cold archive tiering.
- Endpoints: GET /api/v1/config/logging, PUT /api/v1/config/logging

Screen Layout & Bottom Elements (UI கூறுகள் & பட்டன்கள்):

- மேல்புற கட்டுப்பாடுகள் (Top Bar Controls):
 - Page Header with Save Configuration Button and Reset to Defaults Option.
- மத்திய திரைக் கூறுகள் (Tabs & Views):
 - Retention Schedule Slider: Dropdown setting log lifespan (7, 14, 30, 90, 365 days).
 - Traffic Sampling Rate Slider: 1% to 100% sampling controls for ultra-high traffic environments.
 - Privacy Switches: (1) Disable Content Logging (omits prompts/responses), (2) Store Raw Bytes, (3) Auto PII Redaction in logs.
 - External Storage Configuration: AWS S3 / GCS bucket name, region, access key, and secret key inputs.
- கீழ்புற கூறுகள் & ஷீட்டுகள் (Bottom Elements & Sheets):
 - Purge Logs Now Button: Administrative action to instantly delete logs matching selected criteria.
 - Save Logs Configuration Button: Applies changes instantly across all cluster nodes.

Connections & Structure Map (இணைப்புகள்):

- தரவணை பற்றாட்டம்: Admin configurations from the UI.
- இயக்கம் கூறுகள்: Governs the storage lifecycle, privacy masking, and deletion behavior of LLM Logs and MCP Logs.

Production Use Case: ஒரு மரூத்துவமனை 'HIPAA Compliance' விதிப்படி, நோயாளிகளின் உரையாடல்களை 30 நாட்களில் ஆட்டோ-டெலீட் செய்ய Retention-ஐ 30 நாட்களாக அமைத்து, Content Logging-ஐ ஆஃப் செய்கிறது.

3. Cross-Feature Interconnections & Data Flow

Source Feature	Connected To	Data Flow & Action
LLM Logs	Dashboard	Computes token counts, latencies, and costs for realtime charts.
LLM Logs	Connectors	Pushes asynchronous event payloads to Datadog, Kafka, and BigQuery.
MCP Logs	MCP Gateway	Records input JSON arguments and tool execution outputs.
Browser AI	LLM / Audit Logs	Intercepts web AI paste events and logs DLP violations.
Logs Settings	LLM & MCP Logs	Enforces data retention schedules and automated PII redaction.

4. Tech vs Non-Tech Comparative Matrix

Feature	Non-Tech View (Manager / CFO)	Tech View (DevOps / Architect)
Dashboard	How much did we spend on AI this week? Is budget on track?	What are the p95 latency curves and WebSocket health metrics?
LLM Logs	What did the customer ask and was the AI answer accurate?	What was the HTTP status code, TTFT (ms), and pgx insertion rate?
MCP Logs	Is the autonomous agent using company tools responsibly?	Did the stdio/SSE transport succeed with valid JSON schema outputs?
Browser AI	Are employees leaking company secrets on web ChatGPT?	Is the local mitmproxy daemon running with active Presidio DLP filters?
Connectors	Is AI consumption appearing automatically in our billing system?	Are Kafka event streams and BigQuery streaming inserts zero-drop?
Logs Settings	Are we compliant with GDPR and HIPAA 30-day auto-purge rules?	Is the Postgres vacuuming routine and S3 archival pipeline healthy?